Laboratorio 11 — MLOps aplicado al observatorio

Informe técnico integrado · estado al 30 de octubre

Equipo de proyecto · Ciencia de Datos (CC3084), Universidad del Valle de Guatemala

30 de octubre de 2026

1. Alcance y estado de la entrega

El flujo estima visitantes únicos mensuales del polígono Antigua Guatemala para enero y febrero de 2026, meses sin cobertura de telefonía. Integra preparación, controles, factor de reparto, validación temporal, regla de aceptación y trazabilidad. Este documento reúne el alcance del avance, la evaluación existente y la implementación de MLflow/Docker. No modifica las fórmulas ni los umbrales.

Estado: la publicación, la pestaña de Antigua, el monitoreo y la restauración todavía no están integrados en la versión revisada. Por eso este PDF no presenta esos ejercicios como terminados. La base mensual institucional no está en este equipo: las comprobaciones nuevas son sintéticas, identificadas como tales. Los resultados reales de la sección 4 proceden del documento de evaluación del equipo, no de una nueva ejecución con datos institucionales.

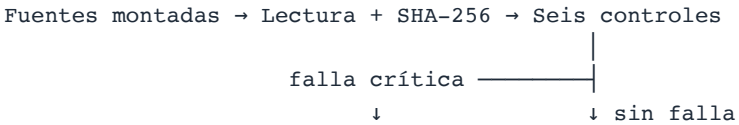
Fuentes editables integradas: `docs/lab11/alcance.md`, `docs/lab11/evaluacion.md` y este documento. Código: repositorio privado `nicoCT04/Lab10-DataSicence`. Entrega prevista: 1 de noviembre de 2026.

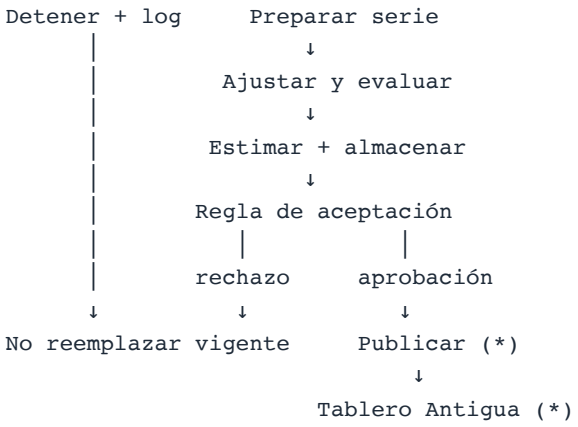
2. Datos, procedimiento y flujo

Elemento	Definición
Variable	Visitantes únicos del mes, unidad personas, agregación destino-mes
Telefonía	`BD_moviidad_mensual.xlsx`, hoja Antigua; destino, anio, mes, fecha, pais, es_consecutivo y visitantes
Migración	`Base_Migracion_2009-2026jun.xlsx`, hoja Datos; Año, Mes cod, Tipo de Viajero y Viajero
Ajuste	Septiembre–diciembre 2025 y marzo–junio 2026: ocho meses con ambas fuentes
Evaluación	Abril–junio 2026, ocultando cada mes y usando únicamente los anteriores
Salida candidata	`mlops/runs/<run_id>/estimates.csv`, dos filas para enero–febrero 2026
Salida prevista del tablero	`mlops/published/current/estimates.csv`, solo si se autoriza y publica

La migración usa turistas más excursionistas. Se suman países y segmentos dentro del polígono principal, no los subdestinos, para evitar duplicar visitantes. Tampoco se suman presencias diarias para obtener visitantes únicos mensuales. Julio–agosto 2026 quedan fuera del ajuste porque la migración termina en junio. Los meses sin cobertura permanecen ausentes, no se rellenan con cero.

El factor de cada mes es $\mathbf{f_t = V_t / M_t}$; el procedimiento utiliza el promedio de esos factores en los meses de ajuste y estima $\mathbf{\hat{V}_t = \hat{f} \times M_t}$. No hay componente aleatorio; la semilla 2026 queda registrada. El archivo `params.json` guarda los parámetros necesarios para reproducir la fórmula, en lugar de un archivo de modelo entrenado. La versión es `factor-reparto-1.0`.





MLflow registra cada ejecución, sus resultados y sus fallos.
(*) Etapas todavía pendientes de integración.

3. Controles automáticos

Control	Criterio crítico	Advertencia permitida
Columnas y tipos	Falta una columna indispensable o su tipo es incompatible	Ninguna
Fechas y cobertura	Fecha inválida o mes necesario ausente	Telefonía fuera de los períodos configurados
Unicidad	Clave duplicada de telefonía o fila idéntica	Clave de migración repetida, que se agrega
Faltantes	Visitantes, fecha o Viajero ausentes	País o permanencia promedio ausentes
Valores y denominadores	Negativos, no finitos o migración mensual cero	Ninguna
Regla metodológica	Fuente diaria, fecha diferente del día 1 o polígono principal ausente	Ninguna

Cada ejecución produce `quality_report.json` y su versión Markdown. Una falla crítica detiene el flujo antes de generar estimaciones. Los resultados de todos los controles disponibles se registran como etiquetas en MLflow; los controles no ejecutados conservan ese estado, no se consideran aprobados.

4. Validación temporal y regla de aceptación

La validación utiliza ventana expansiva: para cada mes de abril a junio se estima el factor solo con meses observados anteriores. La referencia usa el último valor observado bajo la misma restricción temporal. Ambos se comparan sobre exactamente los mismos meses. MAE y RMSE se expresan en visitantes; MAPE, en porcentaje. Los observados cero se excluyen únicamente de MAPE y se informa su cantidad; si todos son cero, MAPE no es calculable.

Se aprueba únicamente si: (1) no falla ningún control; (2) existen los dos meses esperados con valores finitos y no negativos; (3) MAPE ≤ 15 %; y (4) MAE candidato / MAE referencia ≤ 1.25. Los umbrales fueron fijados en el avance, antes de la evaluación. Para una escala cercana a 940 mil visitantes mensuales, 15 % equivale aproximadamente a 140 mil; la razón 1.25 tolera un 25 % adicional de error frente a la referencia por la incertidumbre de evaluar solo tres meses. No se modificaron para aprobar la versión.

Resultado institucional reportado por el equipo en `evaluacion.md`: MAPE 7.4 % y razón MAE 1.38. Cumple el umbral absoluto, pero supera 1.25 y se **rechaza**. Las estimaciones candidatas reportadas son 1,042,620 y 821,310 visitantes para enero y febrero. No son una versión aprobada. Estos números se conservan como resultados documentados por el equipo, pendientes de reproducción en este entorno cuando esté disponible la fuente mensual.

No hay telefonía de enero–febrero en ningún año ni comparación interanual. La migración presenta una ruptura metodológica entre 2022 y 2023; se usan solo 2025–2026. La validación de abril–junio no reproduce completamente la situación de enero–febrero. Además, el factor constante no representa todos los cambios estacionales y la muestra de evaluación es pequeña. No se calculan errores para meses sin observados comparables.

5. MLflow y reproducibilidad

Se fijó **MLflow 3.17.2**. El experimento `observatorio-antigua` almacena los siguientes elementos:

Registro	Evidencia conservada
Identidad	ID de MLflow, ID del pipeline, inicio, fin y estado
Código	Commit Git; dentro de Docker se recibe mediante GIT_COMMIT
Datos	Archivo, hoja, filas y huella SHA-256 de cada fuente leída
Configuración	Períodos, procedimiento, semilla, umbrales y config.toml
Procedimiento	params.json con factor y meses utilizados
Evaluación	Métricas de candidato/referencia y evaluación mensual; decisión y motivo
Calidad	Estado de cada control y reportes originales
Entorno	environment.json con Python y versiones de dependencias instaladas
Artefactos	Estimaciones, serie preparada, parámetros, configuración, reportes y run_log.json

Una detención por calidad se muestra como `FAILED` y conserva su causa. Si no alcanzó la evaluación, no se registran métricas. Una versión rechazada por desempeño sí puede figurar como `FINISHED`, porque terminó la evaluación; la etiqueta `acceptance.approved=False` impide confundirla con una autorización de publicación. Los Excel originales no se copian a MLflow.

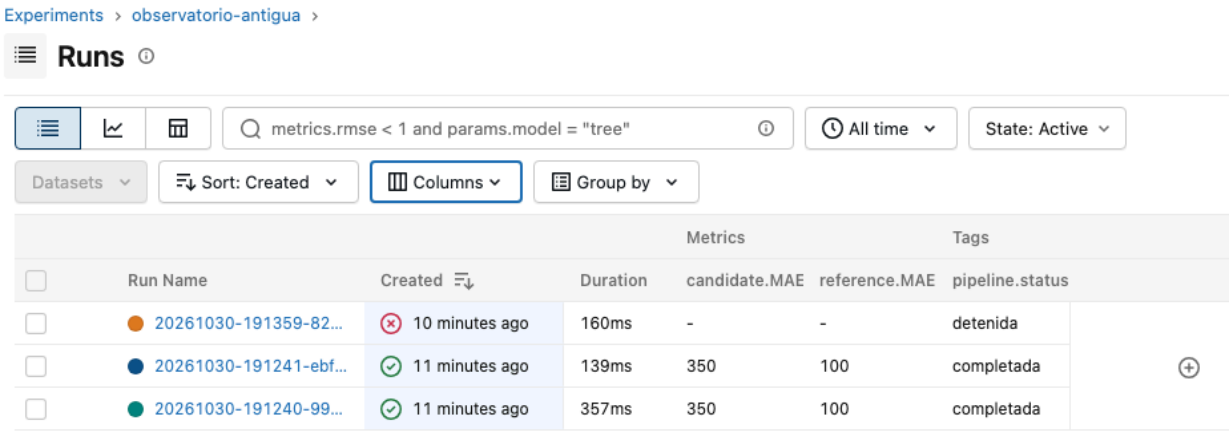
Comprobación técnica sintética

Se utilizó la estructura de `synthetic()` de las pruebas: migración constante de 300 y telefonía del polígono creciendo de 1000 a 1700 en los ocho meses de ajuste. Los subdestinos siguen separados. No son conteos reales de Antigua. La tendencia permite comprobar errores distintos de cero: MAE candidato **350**, RMSE **352.3729085310996**, MAE referencia **100**, razón **3.5**. Ambas ejecuciones terminan, pero ambas candidatas se rechazan con los umbrales originales.

`python -m mlops.reproduce` ejecutó dos veces los mismos archivos y configuración. Comprobó huellas, código, parámetros, evaluación, métricas y estimaciones. La diferencia máxima entre estimaciones fue **0**; las métricas también coincidieron. Se usa tolerancia relativa `1e-12` y absoluta `1e-8` para diferencias de punto flotante en valores y métricas; parámetros y evaluación coinciden exactamente. Solo se excluyen ID y fecha de generación de la comparación de tablas. La equivalencia demuestra reproducibilidad técnica, no precisión ni aceptación del procedimiento.

Se ejecutó además una copia sintética con denominador cero: el proceso terminó con código 1, MLflow registró `FAILED`, explicó el control que falló y no agregó métricas ni estimaciones. Las pruebas automatizadas también cubren corregir el denominador y ejecutar de nuevo. Esto verifica detención y trazabilidad; **no demuestra todavía recuperación de una versión publicada**.

Evidencia consultable: `evidencia/comparison.json`, `evidencia/runs_export.json` y `evidencia/mlflow_runs.txt`. La exportación contiene dos runs completos y uno fallido. Las bases SQLite, artefactos y logs completos permanecen en los volúmenes locales; deben entregarse por el medio autorizado junto con los registros institucionales definitivos.



6. Docker y ejecución desde un clon limpio

La imagen usa Python 3.14 e instala los requisitos del tablero y del flujo. Copia explícitamente código, estilos y predicciones originales del Lab 10. `.dockerignore` excluye fuentes, cachés, entornos, secretos, `.git` y registros; las fuentes se montan, nunca se incorporan a la imagen.

Servicio	Función	Acceso local	Persistencia
tablero	Ejecutar Dash, sin ajustar modelos al filtrar	127.0.0.1:8050	data y published, solo lectura
pipeline	Ejecución única solicitada por comando	No expone puerto	runs, mlruns y published

Servicio	Función	Acceso local	Persistencia
mlflow	Consultar parámetros, métricas y artefactos	127.0.0.1:5001	mlruns con SQLite y artefactos

Los comandos completos de construcción, inicio, consulta, detención y cambio de versión del código están en el README. Se comprobó la construcción y ejecución desde un **clon local limpio del commit de implementación**, sin copiar entornos ni resultados previos. Solo se agregaron fuentes sintéticas montadas para el pipeline; el tablero usó el Excel de migración ya versionado.

Se comprobaron las dos corridas, la falla por denominador cero y la consulta de registros. Tras `docker compose down` y `up`, los tres runs continuaron disponibles. Esta prueba demuestra que la eliminación de contenedores no elimina el almacén, no que ya exista una versión aprobada restaurable. Los puertos quedan vinculados a localhost; no se habilitó despliegue público ni acceso a microdatos.

No mezclar almacenes creados fuera y dentro de Docker: sus rutas absolutas de artefactos difieren. Para respaldar, detener los servicios y conservar juntas las carpetas `mlruns`, `mlops/runs` y, cuando exista publicación, `mlops/published`. La entrega de fuentes y registros institucionales se hace por Canvas/OneDrive autorizado, no mediante enlaces públicos.

7. Rúbrica y pendientes de integración

Criterio	Puntos	Estado verificable
Pipeline y configuración	20	Flujo y configuración existentes; publicación pendiente
Controles de calidad	15	Seis controles; pruebas sintéticas y detención comprobadas
Registro MLflow	15	Implementado y verificado con dos corridas y un fallo; falta repetición institucional
Validación y aceptación	15	Ventana expansiva y regla existentes; sin cambiar umbrales
Integración y publicación	10	Pendiente: publish.py y pestaña de Antigua
Monitoreo y recuperación	15	Pendiente: alertas, conservación y restauración demostrada desde el tablero
Docker y documentación	10	Tres servicios, volúmenes y prueba desde clon limpio; documentación de restauración pendiente de su implementación

No se asigna una nota automática. Antes de la entrega final deben integrarse la sección de fallo, monitoreo/recuperación y tablero del compañero responsable, ejecutar con las fuentes institucionales, entregar los registros completos y confirmar acceso privado del docente e inscripción en Canvas.

8. Referencias

- Equipo de proyecto. (2026). *Alcance del flujo MLOps* y *Validación temporal y regla de aceptación*. Documentos internos del repositorio, `docs/lab11/alcance.md` y `docs/lab11/evaluacion.md`.
- MLflow. (s. f.). *MLflow Tracking*. https://mlflow.org/docs/latest/ml/tracking
- Docker. (s. f.). *Docker Compose*. https://docs.docker.com/compose/
- Universidad del Valle de Guatemala. (2026). *Laboratorio 11: MLOps aplicado al Observatorio de Inteligencia Turística*. Enunciado del curso CC3084.